

Discussion Float Question 1

name : 张贤

(1) 定点数

小数点位置固定的浮点数

优点 : 计算时与整型完全相同, 可以应用整型的计算方法, 计算效率更高

缺点 : 可以处理的精度范围比较低, 可能会需要调整缩放比

区别: 定点数

在特定环境如表示金钱(固定两位小数)时比较好用

(2) 与浮点数有关的故事

1. 1996年阿丽亚娜5号飞船首飞事故 : 代码中有一部分将64位浮点类型强制转换成了16位整型, 在4号中没有出现问题, 而由于5号的飞行速度超过了16位整型范围导致异常溢出激活了错误的程序——损失5亿美元

2. 1991年爱国者导弹防御系统失灵 : 防御代码中使用了一个定点寄存器来处理时间, 单位位 $\frac{1}{10}$ 秒(循环小数). 定点寄存器会截断这个小数而产生一定误差(约 $10^{-8}s$), 经过累计达到 $0.34s$, 导致对导弹轨迹运算产生问题——导致28人死亡, 约100人受伤

(3) 浮点数的表示

$$f = (-1)^s M 2^E$$

s : *Sign* 符号位

M : *Mantissa* 尾数

E : *Exponent* 指数

MSB : *Most Significant Bit* 最高有效位

exp : *exponent field* 指数域

$frac$: *fraction field* 尾数域

$Bias$ 偏移量

符号位

其中 $s = 0$ 时浮点数为非负, $s = 1$ 时浮点数为负

E与exp的关系

E 全0或全1时为denormalize非规格化数,其余情况为normalize规格化数

对于规格化数 $E = exp - bias$

$exp = 0$ 时 $E = 1 - bias$

exp 全1时,若 $M = 0$ 表示 ∞ 或 $-\infty$,否则表示NaN非数字

对于偏移量bias

对n位符号位的浮点数

$$bias = 2^{n-1} - 1$$

E 的范围是 $-2^{(n-1)} + 2 \leq E \leq 2^{n-1} - 1$

float: $n = 8, bias = 127, -126 \leq E \leq 127$

double: $n = 11, bias = 1023, -1022 \leq E \leq 1023$

tip

由非规格化数过渡到规格化数是连续的

exp部分单独设置了全0和全1的非规格化情况

在非规格化情况下可以表示更接近0的数

(4) 规格化的一个例子

对于 $x = -12.75$

$$s = 1$$

$$12.75 = 8 + 4 + \frac{1}{2} + \frac{1}{4}$$

$$M = 110011, frac = 10011, E = 3$$

$$exp = 10000010$$

$$ans = 0xc14c0000$$

(5) 非规格化的一个例子

对于 $x = -12.75 \times 2^{-130}$

$$s = 1$$

$$M = 1.10011, frac = 110011, E = -127$$

$$exp = 0$$

$$extra = 2^{-1}$$

$$ans = 0x80660000$$

对于非规格化改成1-bias主要是为了“平滑过渡”,这保证了从非规格化数到最小的规格化数仍然满足Equispaced(等间距的).而对于规格化数,只有相同exp时才有Equispaced性质.

对于+0和-0,这可能对于求极限等科学计算保留符号信息有帮助,而且实际上因为浮点数的特性,确实有 ϵ 与 $-\epsilon$ 不能被表示出来,但是他们实际上是有符号的

但是+0与-0在比较大小时应当是相同的,但是两个不一样的二进制表示

此外, $\frac{1.0}{-0} \neq \frac{1.0}{0}$,但 $-0 = 0$

(6) 无穷与NaN

浮点型的运算本身就比较复杂,有资源提供额外信息

无穷:

本身浮点型能表示的范围更大,“无穷”比整型上的“无穷”更接近真正的无穷大

无穷可以给出明确提示

非数字:

NaN可以处理非实数情况,并且明确具体在哪一步出现问题

Nan的存在不能简单比较大小

IEEE 754 标准定义了两种 NaN: 安静 NaN (Quiet NaN, qNaN) 和信令 NaN (Signaling NaN, sNaN)

最高位若为1位qNaN, 0为sNaN

其中qNaN会使程序继续运算,直到最终出现NaN异常,通常用来处理 $\frac{0}{0}$ 或 $\sqrt{-1}$ 等情况

sNaN则会立刻输出异常信息,例如会表示未初始化的变量

其他位也会用来储存一些诊断信息